Diagnóstico de calidad de datos

1. Qué se revisó y cómo

Revisamos el conjunto de trabajo de la segmentación RFM: una fila por cliente, 599 clientes y 9 columnas. Miramos la estructura y los tipos de dato, los nulos, los duplicados por clave, los estadísticos con percentiles y los valores atípicos con el criterio IQR. Después aplicamos los controles propios de la variante, enunciamos reglas de negocio y las verificamos, y reconciliamos las tablas con el origen. Los controles se calcularon en SQL Server y en pandas para comparar los resultados.

2. Estructura y estadísticos

Las 9 columnas tienen sus 599 valores y 0 nulos. Los tipos de dato son los esperados: *id_cliente*, *recencia_días* y *frecuencia_alquileres* son enteros, *monto_total* es decimal y *nombre_cliente* y *segmento_RFM* son texto. No hay duplicados por *id_cliente*.

Estadístico	Recencia (días)	Frecuencia (alquileres)	Monto total ($)
Mínimo	0	12	50,85
Percentil 25	0	23	94,785
Mediana	175	26	110,73
Percentil 75	176	30	128,705
Percentil 95	177	35	155,596
Máximo	181	46	221,55
Promedio	129,24	26,78	112,53

3. Hallazgos y decisiones

Para cada hallazgo dejamos la evidencia, lo que decidimos hacer y por qué.

Hallazgo	Decisión	Fundamento
No hay nulos ni clientes duplicados (0 en las 9 columnas, 0 duplicados por id_cliente).	No se imputa ni se elimina nada.	No hay nada que corregir: el RFM se calcula sobre los 599 clientes.
Hay 6 valores atípicos de monto (1 %): de $186,62 a $221,55, fuera del límite superior de $179,58 (Q1 $94,78, Q3 $128,70).	Se conservan.	Son clientes con muchos alquileres (de 38 a 46), así que el monto es coherente. No son negativos ni duplicados, así que no hay evidencia de error.
La recencia está muy concentrada: el percentil 25 es 0, la mediana es 175 y el máximo es 181. Al menos una cuarta parte de los clientes tiene recencia 0.	No se transforma ni se descarta. Los empates se desempatan por id_cliente.	Son valores reales de la base. El desempate hace que el resultado sea siempre el mismo, pero es un criterio arbitrario: lo declaramos como limitación.
La tabla de pagos en SQL Server tiene 16.044 filas y el original 16.049 (5 menos).	No se reconstruyen filas. Se deja la diferencia documentada.	Es consistente con pagos sin alquiler que no se migraron, pero no se puede confirmar porque esas filas no están en SQL Server.

4. Controles de la variante

La ficha pide controlar los clientes sin ningún pago y los pagos sin alquiler asociado, es decir, los pagos con la clave de alquiler en NULL, que es un defecto conocido de algunas versiones de Sakila. Todos los controles dieron lo mismo en SQL Server y en pandas.

Control	SQL Server	Pandas	Coincide
Clientes duplicados	0	0	Sí
Pagos sin alquiler asociado	0	0	Sí
Monto de los pagos sin alquiler	0	0	Sí
Clientes sin ningún pago	0	0	Sí
Pagos negativos	0	0	Sí

En la base migrada a SQL Server no aparece el defecto conocido: no hay pagos sin alquiler que cambien el total de ingresos.

5. Reglas de negocio

- **Regla 1:** no se admiten montos negativos. Violaciones: 0.
- **Regla 2:** la recencia no puede ser negativa. Violaciones: 0.
- **Regla de integridad:** un pago no puede estar asociado a un cliente distinto del que hizo el alquiler. Violaciones: 0.

6. Reconciliación con el origen

Comparamos las 16 tablas de Sakila contra el volcado original. 15 coinciden en cantidad de filas. La única diferencia es *pago* (*payment*): 16.049 filas en el origen y 16.044 en SQL Server, 5 menos. Es consistente con pagos sin alquiler que no se migraron, pero no podemos confirmarlo porque esas filas no están en SQL Server.

7. Lo que decidimos no corregir

- **Los 6 valores atípicos de monto:** se conservan porque son clientes de alto valor plausibles.
- **La concentración de la recencia:** es un rasgo real de los datos. No se cambia, se desempata y se declara como limitación.
- **Los 5 pagos de diferencia:** no se inventan ni se reconstruyen. Quedan documentados.